

Vehicle ReID Lab

Техническое руководство и отчёт об экспериментах

Задача: по фотографии автомобиля найти тот же автомобиль в галерее другой камеры и отказаться от совпадения, когда правильного автомобиля в галерее нет.

Поиск	Отказ	Скорость
0.892 mAP@10 5-fold identity-disjoint OOF	0.863 nested $0.7 \times F1 + 0.3 \times TNR$	16.6 мс / 532 FPS H200, прежний экспорт той же архитектуры

Публичный LLM2CLIP EVA02-L-14-336 → MAD-Cars full pretrain epoch 7 с tilt-аугментацией → дообучение на пяти независимых по vehicle_id фолдах → full retrain на всех размеченных identity → 256-мерный признак → cosine top-10 и отдельный open-set отказ на базе cosine + CatBoost.

Документ переводит и структурирует техническое содержание README.md и результатов ноутбуков. Числа относятся к явно указанным протоколам: ранний labeled-only, финальный MAD-Cars OOF, аппаратное профилирование прежнего экспорта или финальный Docker serving не смешиваются.

Версия документа: 27.09.2026. Исходный репозиторий: ReID. Основной YAML: configs/experiment/current_best_tuned_madcars_full.yaml.

Поток данных в финальном inference



Выход: submission.csv (top-10 для каждого query), embeddings.npy (query/gallery признаки), candidates.csv (пары, прошедшие open-set отказ).

Содержание

01. Краткое описание итогового решения	4
Что вошло, что осталось исследованием	4
02. Запуск по шагам и устранение ошибок	5
2.1. Быстрый конкурсный запуск в Docker	5
2.2. Куда класть данные	5
2.3. Локальная среда разработки и полный цикл	6
2.4. Типовые ошибки и действия	6
03. Обзор кодовой базы	8
04. Что поддерживает код и что настраивается	9
05. Внешние данные и pretraining	10
5.1. Публичные веса и сравнение датасетов	10
5.2. Почему MAD-Cars и зачем tilt	10
5.3. Воспроизведение full MAD-Cars pretrain	11
5.4. VeRi, VRIC и SSL как альтернативы	11
06. Как устроена валидация	13
6.1. GroupKFold по vehicle_id	13
6.2. Junk и различие между локальным и файловым scorer	13
6.3. Доверительные интервалы и сложные срезы	13
6.4. Отдельная вложенная валидация refusal	14
07. Модели, обучение и Optuna	15
7.1. Zero-shot проба backbone	15
7.2. Основное обучение	15
7.3. Что тюнила Optuna	16
08. Итоговый конфиг и метрики	18
8.1. Точная конфигурация serving recipe	18
8.2. Реально включенные training-аугментации	18
8.3. Основные результаты	19
09. OOF-анализ и сложные случаи	20
9.1. Что изменил MAD-Cars pretrain	20
9.2. Срезы сложности	21
10. Full retrain, экспорт и воспроизводимость	24

10.1. Выбор числа эпох	24
10.2. Экспорт embedding модели и refusal head	24
11. Профилирование: H200, A5000, RTX 3090 и TensorRT	25
11.1. Что именно измеряется	25
11.2. PyTorch профили на трех GPU	25
11.3. Полный replay и совместимость CUDA	26
11.4. ONNX → TensorRT как опция	27
12. Open-set refusal: протокол, модели и результат	29
12.1. Что должен решить отказ	29
12.2. Данные обучения и признаки CatBoost	29
12.3. Nested calibration и выбор ensemble	29
13. ТТА, postprocessing и псевдоразметка	32
13.1. Какие операции совместимы с потоковым тестом	32
13.2. HDBSCAN test pseudo-labels: что делали и почему не взяли	32
14. Интерпретация embedding и cosine пары	34
15. Пост-хок устойчивость к искажениям	36
16. Локальный image matching: EfficientLoFTR	38
17. Неудавшиеся и невыбранные эксперименты	40
Итоговые границы утверждений	40
18. Проверки, артефакты и карта источников	41
18.1. Контроль после воспроизведения	41
18.2. Где искать первоисточник каждого числа	41

01. Краткое описание итогового решения

Это open-set vehicle re-identification. На входе находятся `test_query.csv`, `test_gallery.csv` и каталог изображений. Для каждого query модель извлекает признак, ранжирует статическую gallery и отдельно решает, есть ли в ней правильная identity. Номерной знак не нужен. В закрытом тесте около 20% query не имеют пары в галерее; эти запросы не помечены.

Этап	Итоговая реализация
Инициализация	Публичные веса LLM2CLIP EVA02-L-14-336.
Внешние данные	MAD-Cars, full pretrain до epoch 7; имитация верхнего ракурса tilt.
Датасет задачи	9 556 train-кропов, 1 541 vehicle_id, 96 камер; 5-fold GroupKFold по identity.
Обучение	РК 16×4, camera-diverse, ArcFace + AdaSP, EMA; 35 эпох как CV-бюджет.
Финальная модель	Full retrain 17 эпох на всех размеченных identity; EMA, 256-D embedding.
Ранжирование	Cosine top-10; TTA и retrieval postprocessing в serving выключены.
Open-set	Принимаем запрос только если $\max \text{cosine} \geq 0.5854$ и $\text{CatBoost } P(\text{match}) \geq 0.4034$.
Поставка	Offline Docker; <code>submission.csv</code> , <code>embeddings.npy</code> , <code>candidates.csv</code> .

Главный результат: пять identity-disjoint OOF фолдов дают mAP 0.900, mAP@10 0.892, Rank-1 0.902. Это локальная оценка на fold-моделях, а не скрытый test score. Финальный .pt обучен на всех train identity и не может честно оцениваться на тех же fold validation.

Что вошло, что осталось исследованием

Статус	Методы
В serving	MAD-Cars ep7 → EVA02 full retrain; bbox crop + 6.2% контекста; BNNeck, attention pooling, EMA; cosine ranking; AND отказ cosine + CatBoost.
Изучено, но не включено	VeRi/VRIC, SSL, другие backbone и loss, усиленные аугментации, TTA, gallery aggregation, GNN/k-reciprocal rerank, EfficientLoFTR, TabM, ONNX/TensorRT.
Запрещено для submission	Псевдоразметка test через HDBSCAN и query expansion/AQE; результаты сохранены как исследовательские OOF-эксперименты.

02. Запуск по шагам и устранение ошибок

2.1. Быстрый конкурсный запуск в Docker

Для готового inference хосту нужны Docker с доступом к NVIDIA GPU, репозиторий и реальные файлы весов из Git LFS. Хосту не нужны локальные uv и Python. Во время `docker build` сеть возможна; `docker run` работает без сети. Базовый образ: `pytorch/pytorch:2.8.0-cuda12.8-cudnn9-runtime`; внутри ставится `gcc` для компиляции PyTorch kernels.

```
git lfs pull
mkdir -p runs/submission
docker compose build
DATA_ROOT=./data OUTPUT_DIR=./runs/submission docker compose run --rm retrieval
```

Если `git lfs pull` не скачивает бинарные файлы или оставляет вместо них LFS pointers, загрузите `eva02.pt` и `eva02_catboost.cbm` из https://huggingface.co/lightsource/eva_mad_model вручную. Положите их в `weights/finetuned/` под этими именами рядом с `SHA256SUMS` из репозитория. При наличии Python 3 на хосте проверьте файлы командой `python3 scripts/verify_weights.py --root weights/finetuned`; Docker build в любом случае повторит проверку checksum.

После запуска проверьте `runs/submission/submission.csv`, `embeddings.npy`, `candidates.csv`. Docker копирует внутрь `weights/finetuned/eva02.pt` и `eva02_catboost.cbm`; не монтируйте поверх `/app/weights` пустую папку. Compose монтирует `data/` только для чтения в `/data`, результаты пишет в `/runs/submission`, использует `--gpus all`, `network_mode: none` и `refusal=eva02_ensemble`.

2.2. Куда класть данные

```
data/
  train.csv
  test_query.csv
  test_gallery.csv
  images/
    <image_id>.jpg
```

У каждого CSV обязательны `image_id,x,y,w,h`; `train.csv` дополнительно требует `vehicle_id`. Для кросс-камерной валидации нужен `camera_id`. Если расширения нет, loader ищет `.jpg`, `.png`, `.jpeg`. Координаты `bbox` обрезаются по размеру изображения; пустые, повторные и некорректные аннотации отклоняются. В тесте `vehicle_id` не нужен.

Файл результата	Смысл и формат
<code>submission.csv</code>	Без заголовка: <code>query_id + 10 gallery_id</code> в каждой строке; строки для всех query, включая <code>open-set</code> и отвергнутые.
<code>embeddings.npy</code>	Матрица <code>float32</code> : сначала query в порядке CSV, затем gallery в порядке CSV; нормализованные 256-D признаки.
<code>candidates.csv</code>	С заголовком <code>query_id,gallery_id,confidence</code> . Нет строк для отвергнутого query; это и есть отказ. Организаторы не накладывают дополнительный порог.

Команда Docker по умолчанию запускает eval.py с checkpoint=/app/weights/finetuned/eva02.pt, data.root=/data, eval.split=test, eval.top_k=10, eval.fast_kernels=false, refusal=eva02_ensemble. submission.csv определяет ranking mAP@10, а candidates.csv - open-set F1/TNR. Поле confidence в последнем - монотонная similarity, не обязательно калиброванная вероятность.

2.3. Локальная среда разработки и полный цикл

```
python3 -m venv .venv
.venv/bin/python -m pip install -e '[dev]'
make audit
make folds
make smoke
make lint
make test
```

Альтернатива pip: uv sync --extra dev или make setup. Путь через uv читает uv.lock; pip ставит закреплённые прямые зависимости из pyproject.toml, но не фиксирует весь транзитивный граф. Docker собирается из отдельного хешированного requirements/runtime.txt и uv.lock не использует. При обновлении зависимостей: make lock.

Запуск fold-модели: train.py experiment=current_best_tuned_madcars_full init_checkpoint=<MAD-Cars ep7.pt> data.fold=0 data.root=<абсолютный путь>/data. Для CV на пяти GPU используется scripts/train_folds.sh с пятью физическими ID. После CV выполняются mean-stop full retrain, экспорт EMA-весов, обучение CatBoost и Docker inference; подробные команды приведены в главах 5, 7 и 10.

2.4. Типовые ошибки и действия

Симптом	Проверка / действие
Не найдено изображение или пустой crop	Проверить data.root, image_id, каталог images/, расширение и положительные bbox w,h; запустить make audit.
Старый folds.csv или identity leakage	Пересоздать manifest через make folds; не переиспользовать после изменения train.csv, seed или числа folds.
eval.split=val отвергает checkpoint	Для val взять лучший checkpoint того же фолда из run_summary.json; full retrain .pt видел все train identity и годится только для test.
Пустые/неполные веса или checksum mismatch	Убедиться, что Git LFS скачал бинарные файлы, затем выполнить scripts/verify_weights.py; не подменять /app/weights mount-ом.
CUDA OOM	Уменьшить batch/worker count, проверить активные процессы и размеры входа; для HPO OOM trial будет pruned.
Ошибка компиляции torch.compile	Проверить gcc и драйвер; в Dockerfile gcc уже добавлен. Для диагностики можно запустить model.compile=false, но это меняет скорость.
Ошибка CUDA/runtime при запуске контейнера	Проверить nvidia-smi, доступ GPU в Docker и совместимость драйвера. Успешный replay на RTX 3090 с драйвером 535 не доказывает совместимость каждой машины.
Ошибка scales для EVA02	EVA02 фиксирован на 336×336; при TTA оставить eval.tta.scales=[1.0].
Ошибка AQE в streaming	AQE запрещен протоколом; оставить postproc.streaming=true и postproc.aqe.enabled=false.

Симптом	Проверка / действие
Optuna Dashboard: no such table: version_info	Сначала создать study через <code>hpo.run_optuna_search</code> ; Dashboard не инициализирует SQLite-схему сам.

03. Обзор кодовой базы

Репозиторий построен вокруг трех Hydra entrypoint: `pretrain.py` для внешних датасетов, `train.py` для размеченных competition identity и `eval.py` для fold validation или test retrieval. PyTorch Lightning управляет обучением, а Hydra фиксирует состав модели, данные и все параметры. Главные исполняемые пути не зависят от исследовательских ноутбуков.

Каталог / файл	Роль
dataset/	CSV-аудит, deterministic folds, bbox crop, DataModule, pretrain readers, PK sampler.
augmentations/	Упорядоченная config-driven Albumentations/torchvision цепочка; enabled и вероятность у каждого преобразования.
models/	Адаптеры timm/HF/RADIO/LLM2CLIP, pooling, BNNeck и embedding head, SDPA/compile kernels.
modules/	LightningModule, loss registry, метрики, optimizer/scheduler, inference, EMA, R-Drop, AWP.
configs/	Hydra groups: model/loss/optimizer/scheduler/augmentation/refusal/experiment.
hpo/	Optuna search space, изолированные studies, запуск и сбор пяти folds на trial.
refusal/	Признаки retrieval-set, cosine, CatBoost, TabM, вложенный open-set протокол.
postproc/	TTA-adjacent retrieval stages, gallery aggregation, AQE, GNN и k-reciprocal rerank.
interp/, matching/, posthoc/	Интерпретация embedding/cosine, EfficientLoFTR и анализ устойчивости к corruptions.
profiling/	Полный extract() с тем же decode/crop, latency/FPS/VRAM и инвентаризацией весов.
scripts/	Folds, audit, downloads, export, checksum, pseudo-label, zero-shot, CV aggregation.
tests/, third_party/	CPU/offline проверки первого кода; vendored upstream реализации отдельно.

Checkpoints хранят resolved Hydra config и fingerprint разбиения. Продолжение training с иным train CSV, fold или label map отклоняется. Для переноса с pretrain на competition используют `init_checkpoint`, а не `resume`: пространства классов различаются.

04. Что поддерживает код и что настраивается

Весь список ниже описывает возможности кода, а не состав финального serving. Базовая композиция выбирается через Hydra groups; параметры можно переопределять аргументами key=value. Незнакомый loss, неверный mining, нечисловой loss, невалидный augmentation аргумент и несовпадение размерностей признаков обрабатываются как ошибки.

Подсистема	Реализованные варианты
Backbone	timm, Hugging Face Transformers, NVIDIA RADIO, LLM2CLIP/EVA; preset-ы ResNet50, ConvNeXt Tiny, Swin, ViT, DINOv3 ConvNeXt Base/Large/multilevel, RADIO, LLM2CLIP.
Pooling/head	GAP, GeM/signed GeM, max, average-max, attention, CLS; 256-D или иная размерность, BNNeck, dropout, local parts, multi-level fuse.
Loss	ArcFace, CosFace, SphereFace2, AdaSP, triplet и варианты mining, ProxyAnchor/NCA, NT-Xent, SupCon, Circle, FastAP, SoftTriple, Lifted, weighted combined.
Sampling	P×K по vehicle_id, camera-diverse выбор экземпляров, random для SSL.
Оптимизация	AdamW, SGD, LAMB, Lion; cosine/linear/multistep, warmup, layer-wise LR decay, freeze, gradient accumulation/clipping.
Регуляризация	DropPath, R-Drop, AWP, EMA. В финальном YAML R-Drop/AWP выключены, EMA включена.
Augmentation	Geometry, цвет, compression, blur/noise, weather, erase/occlusion, policy transforms; enabled, p, параметры каждого.
Inference	Flip/rotation/scale/context TTA, галерейная агрегация, per-query rerank, optional ONNX/TensorRT; streaming guard.

```
.venv/bin/python train.py model=resnet50 loss=arcface \
  optimizer=adamw scheduler=cosine data.fold=0
.venv/bin/python train.py model.head.embedding_dim=768 \
  model.pooling.kind=gem data.image_size='[320,320]' \
  data.sampler.identities=16 data.sampler.instances=4 train.epochs=30
```

Конфиг содержит data (пути, fold, loader, crop, sampler), model (backend, feature map, pooling, head), loss, augmentation, optimizer, scheduler, train (freeze/EMA/AWP/R-Drop), trainer (устройство и precision), eval (TTA и выход) и postproc. Корневой preset без experiment использует ArcFace + hard triplet, но финальная модель использует ArcFace + AdaSP.

05. Внешние данные и pretraining

5.1. Публичные веса и сравнение датасетов

Перед обучением скачиваются исходные веса DINOv3, RADIO, LLM2CLIP и, при необходимости анализа пар, EfficientLoFTR через `scripts/download_weights.py`. Загрузки сверяются по SHA-256; у RADIO и LLM2CLIP зафиксирован Hub commit. На offline-машине устанавливают `model.local_files_only=true` и указывают локальный `model.checkpoint_path`.

```
.venv/bin/python scripts/download_weights.py llm2clip
.venv/bin/python scripts/download_weights.py dinov3_base
.venv/bin/python scripts/download_weights.py radio
```


Датасет	Формат и назначение	Итог
VeRi-776	extra_data/VeRi/image_train/ и train_label.xml; публичные ID и камеры, кропы авто; CC BY-NC 4.0.	Поддерживается, но не улучшил выбранное решение.
VRIC	extra_data/VRIC/train_images/ и vric_train.txt с image/identity/camera; кадры из UA-DETRAC.	Эксперимент pretrain, результат ниже MAD-Cars.
MAD-Cars	images/<car_id>/<view_id>.jpg, meta/mad.csv, subsample20.csv; около 70 тыс. машин, до ~85 видов, до 1920×1080.	Выбран: ~1.4 млн изображений, 20 видов на авто; ep7.
Конкурсные изображения без меток	Кропы или полные кадры train+test для DINOv3-style SSL.	Изучено, в serving не вошло.

VeRi уже дает вырезанные авто, VRIC тоже; MAD-Cars содержит полные кадры, поэтому reader использует `full_image=True`. Для MAD-Cars `view_id` служит проху камеры при camera-diverse sampling; на competition fine-tune используется реальный `camera_id`. Номерные знаки в использованных изображениях MAD-Cars уже размыты, как и в данных задачи. Наш pipeline не восстанавливает текст номера и не запускает отдельный OCR. Внешние данные не копируются в submission: их можно воспроизвести из открытых источников и нужно учитывать лицензии.

5.2. Почему MAD-Cars и зачем tilt

MAD-Cars снят преимущественно с уровня земли, а камеры задачи смотрят немного сверху. В `configs/augmentation/reid_tilt.yaml` однонаправленный вертикальный shear `y=[-12, -4]` с `p=0.3` и лёгкая Perspective с `p=0.15` имитируют этот сдвиг ракурса поверх остальных настроенных аугментаций. Это гипотеза о domain shift, проверенная отдельно на 20 тыс. машинах и 10 видах в 3-fold CV.

MAD-Cars 20k, 3-fold OOF	mAP	mAP@10	Rank-1
Без tilt	0.8658	0.8562	0.8627
C tilt	0.8774	0.8683	0.8757



Один вид MAD-Cars до и после tilt. Сдвиг имитирует верхний ракурс камер задачи. Источник: notebooks/eva02/readme_figs/madcars_tilt_example.jpg.

5.3. Воспроизведение full MAD-Cars pretrain

Сначала получают публичный mad.csv, затем скрипт выбирает 20 видов на каждую доступную машину и сохраняет manifest. --cars 0 означает все подходящие машины, --min-views 4 отсеивает слишком редкие identity. Повторный запуск продолжает загрузку по тому же manifest. Скрипт run_madcars_full_pretrain.sh сам ничего не скачивает.

```
mkdir -p extra_data/madcars/meta
.venv/bin/hf download yandex/mad-cars mad.csv --repo-type dataset \
  --revision 3fa6f91824d0164029908d7953a1b0483adc38ba \
  --local-dir extra_data/madcars/meta
.venv/bin/python scripts/download_madcars.py \
  --cars 0 --views 20 --min-views 4 \
  --dataset madcars --subsample-name subsample20.csv
scripts/run_madcars_full_pretrain.sh
```

Полный pretrain использует experiment=current_best_tuned_madcars_full и reader madcars_full. Отдельно сохраняется epoch-7 milestone. Из Lightning checkpoint экспортируются EMA-веса для инициализации каждого competition fold и full retrain. Сохраняются backbone/head веса, но не старый classifier для иной identity space.

```
PRETRAIN_RUN=$(ls -dt runs/pretrain/madcars_full/*/ | head -1)
.venv/bin/python scripts/export_serving.py \
  --checkpoint "${PRETRAIN_RUN%}/checkpoints/milestone_epoch007.ckpt" \
  --output runs/pretrain/madcars_full_pretrain_ep7/checkpoints/madcars_full_pretrain_ep7.pt \
  --weights ema
```

5.4. VeRi, VRIC и SSL как альтернативы

scripts/pretrain.sh принимает GPU, Hydra model group, набор датасетов и опциональный experiment. Допустимы veri, vric, veri,vric, both, test_train_ssl_crop и test_train_ssl_full. При смешении источников ID и camera_id ремапятся для отсутствия коллизий. LLM2CLIP принудительно использует 336×336 и local_parts=0.

```
scripts/pretrain.sh cuda:2 llm2clip vric
scripts/pretrain.sh cuda:2 dinov3_convnext_base veri,vric
scripts/pretrain.sh cuda:2 llm2clip test_train_ssl_crop
```

SSL-ветка подает каждое изображение как отдельный экземпляр: DINO self-distillation с Sinkhorn, iBOT masked patches, KoLeo и Gram якорем к EMA teacher. Маскирование token доступно только LLM2CLIP/EVA02; для ConvNeXt, RADIO, timm и HF ibot_weight отключается. Два глобальных вида

EVA02 остаются 336×336 из-за фиксированного RoPE. SSL использовал train и test изображения без их меток; prototype heads при переносе отбрасываются. В финальное решение SSL не вошло.

Pretrain + fine-tune	Протокол	mAP	mAP@10	Rank-1
VRIC → K=4+cam	3-fold OOF	0.820	0.806	0.823
MAD-Cars 20k без tilt	3-fold OOF	0.866	0.856	0.863
MAD-Cars 20k + VRIC	3-fold OOF	0.860	0.849	0.856
MAD-Cars 20k с tilt	3-fold OOF	0.877	0.868	0.876
MAD-Cars full ep7	5-fold OOF	0.900	0.892	0.902

Числа для full MAD-Cars (5 folds) нельзя интерпретировать как прямую абляцию против 20k (3 folds): меняются объём данных и протокол. Чистые pretrain probe метрики на всех train ID тоже нельзя сравнивать напрямую с identity-disjoint OOF.

06. Как устроена валидация

6.1. GroupKFold по vehicle_id

Основной протокол - пять детерминированных identity-disjoint folds. Группа разбиения - vehicle_id, поэтому один автомобиль не попадает одновременно в обучение и validation. Из 1 541 ID в каждом fold примерно 1 233 обучающих и 308 валидационных. Seed, fingerprint аннотаций, число folds и версия протокола записываются в manifest. Если CSV изменился, старое разбиение использовать нельзя.

Validation query выбирается с одной камеры; положительные gallery изображения должны быть сняты другими камерами. Identity без допустимого cross-camera позитива остается distractor в gallery, но не входит в среднее retrieval query. Метрики считаются по полному fold gallery, затем агрегируются OOF по числу query, а не как среднее из пяти усредненных чисел без весов.

Показатель	Определение и роль
mAP	Average precision по полной gallery; monitor выбора best checkpoint и историческая objective Optuna.
mAP@10	AP только по top-10 submission; главный contest ranking показатель.
Rank-1 / Rank-5	Доля query с истинным ID в соответствующем ранге после корректного junk filtering.
mINP	Положение последнего найденного положительного совпадения; дополнительная диагностика.

6.2. Junk и различие между локальным и файловым scorer

Junk - gallery снимок **той же identity и той же камеры**, что query. Другая identity с query-камеры остается в ranking. Если после удаления junk нет ни одного допустимого позитива, query исключается из среднего mAP@10/Rank-1/Rank-5, а не получает AP=0. Для open-set отказа такой query оценивается отдельно в candidates.csv.

В сохраненных validation galleries same-camera same-ID изображения уже отсутствуют. При реконструкции исходной gallery на раннем labeled-only 27-epoch K=4+cam прогоне filter-then-top-10 дал mAP@10 0.847, а запись сырых top-10 с последующим удалением junk эталонным parser - 0.843; Rank-1 не изменился. Это измеренный protocol gap на **старом** OOF, не оценка потери на скрытом тесте или на финальном MAD-Cars OOF. Тестовые CSV не содержат camera_id/vehicle_id, поэтому serving не может заранее вычистить такой junk. В документе это оставлено явно для корректной интерпретации цифр.

6.3. Доверительные интервалы и сложные срезы

Ноутбук oof_analysis.ipynb извлекает per-query AP, AP@10 и Rank-1 на финальном MAD-Cars 5-fold OOF. Затем выполняет 2 000 bootstrap-выборок с seed=0 и считает 95% интервалы для среднего. На этом validation одна query соответствует одной identity, поэтому query bootstrap здесь совпадает с identity bootstrap.

Метрика	OOF point estimate	95% bootstrap interval
mAP	0.900	[0.889, 0.911]
mAP@10	0.892	[0.880, 0.904]
Rank-1	0.902	[0.887, 0.916]

Пять fold mAP: 0.897 / 0.886 / 0.910 / 0.901 / 0.908; стандартное отклонение около 0.008. Bootstrap отражает вариацию запросов на фиксированных fold-моделях. Он не устраняет смещение отбора гиперпараметров по той же CV и не заменяет скрытый тест.

6.4. Отдельная вложенная валидация refusal

Для open-set моделируется тестовая смесь: из gallery удаляются 20% query identity, чтобы около 20% запросов не имели пары. CatBoost/TabM обучаются на 50/50 синтетических full-vs-stripped парах, но пороги и contest F1/TNR подбираются на eval packs с 20% open-set. Во вложенной 5-fold схеме четыре folds обучают head; inner eval выбирает порог; внешняя hold-out fold сообщает результат с уже замороженным порогом. F1 и TNR считаются micro по одной общей confusion matrix, не средним по identity.

Валидацию финального .pt на train folds выполнять нельзя: после full retrain модель видела все train identity. Отчётные retrieval OOF 0.892 и refusal 0.863 принадлежат fold-моделям/вложенным packs; перенос правил на финальный .pt - выбранное serving решение, а не новая held-out метрика.

07. Модели, обучение и Optuna

7.1. Zero-shot проба backbone

Перед fine-tune четыре крупных модели проверялись без обучения на всех train.csv ID: один query на identity при наличии cross-camera позитива, остальное gallery (1 541 query и 5 550 gallery). Отключались случайная проекция, BNNeck и attention pooling, чтобы измерить исходный backbone. Это **не** тот же split, что 5-fold OOF обученной модели.

Backbone, без fine-tune	mAP	mAP@10	Rank-1	Rank-5
DINOv3 ConvNeXt Base	0.168	0.141	0.162	0.286
DINOv3 ConvNeXt Large	0.182	0.152	0.167	0.310
RADIO C-RADIOv4-SO400M	0.148	0.123	0.147	0.263
LLM2CLIP EVA02-L-14-336	0.301	0.268	0.313	0.471

EVA02 имела наилучшую исходную retrieval-геометрию; затем выбранный рецепт ConvNeXt Search перенесли на нее и отдельно настроили 336×336, PK 16×4, camera-diverse sampling. Увеличение модели сверх этого могло ухудшить конкурсный балл по скорости; итоговая архитектура укладывается в порог 100 FPS и 40 мс на измеренных машинах.

7.2. Основное обучение

```
.venv/bin/python train.py experiment=current_best_tuned_madcars_full \
  init_checkpoint=runs/pretrain/madcars_full_pretrain_ep7/checkpoints/madcars_full_pretrain_ep7.pt \
  data.fold=0 data.root="$PWD/data"
```

Для полной 5-fold оценки на пяти GPU скрипт сам готовит folds, запускает отдельные train.py и eval.py, затем собирает cv_metrics.json, oof.csv и oof_embeddings.npy. Каждый GPU ID сопоставляется одному fold; путь к публичному checkpoint передается отдельно от MAD-Cars transfer-init:

```
EXPERIMENT=current_best_tuned_madcars_full \
RUN_ROOT=runs/cv/madcars_full_ft_ep35 \
MODEL_CHECKPOINT=weights/llm2clip/LLM2CLIP-EVA02-L-14-336.pt \
scripts/train_folds.sh 3,4,5,6,7 \
  init_checkpoint=runs/pretrain/madcars_full_pretrain_ep7/checkpoints/madcars_full_pretrain_ep7.pt \
  data.root="$PWD/data"
```

train.py строит PyTorch Lightning module с manual optimization. В определенном порядке исполняются накопление градиента, AWP (если включен), optimizer step, scheduler и EMA. Для multi-GPU при trainer.strategy=auto выбирается DDP. Каждый fold сохраняет resolved config.yaml, split CSV, label_map.json, логи, best и last checkpoint. resume разрешен только с совпадающими fingerprint данных и label map; init_checkpoint переносит только модель из другого identity space.

В базовом Hydra-проекте можно выбирать любые поддерживаемые backbone/loss/pooling; финальная конфигурация отличается от корневого combined-loss preset: она использует 256-D neck embedding, attention pooling, ArcFace + AdaSP и EMA. AdaSP требует как минимум две identity и два изображения на identity в PK batch; camera-diverse sampling предпочитает разные камеры внутри класса.

7.3. Что тюнила Optuna


Search runner обучает пять folds на trial, выбирает best checkpoint и максимизирует query-weighted OOF метрику. Ключ `--metric` меняет также Lightning monitor `val/{metric}`, чтобы выбор checkpoint был согласован с objective. Все trials хранятся в SQLite `artifacts/optuna/<study>.db`, с точными Hydra overrides, логами, кодами завершения и метриками; запуск с тем же именем продолжает study. OOM trial pruned, а ошибка отдельного fold не останавливает весь study.

Тюним	Фиксируем внутри study
Размер input и context bbox; P×K; backbone LR multiplier/layer decay; pooling/head; loss и его параметры; optimizer/scheduler/warmup; EMA, DropPath, R-Drop/AWP; каждый augmentation enabled/p/params; TTA; разрешенные gallery aggregation и per-query rerank.	Архитектуру и исходный checkpoint конкретной study; dataset, 5-fold manifest, seed, deterministic mode, workers, precision, логирование, сохранение checkpoints и пути вывода.

`--space contest` принудительно оставляет `postproc.streaming=true` и не включает AQE. Отдельная исследовательская `nonstreaming study` допускает AQE, но ее trials нельзя смешивать по имени с `contest-space`. Скрытые test query не участвуют в выборе финального конфига.

```
.venv/bin/python -m hpo.run_optuna_search \  
  --model dinov3_convnext_base \  
  --checkpoint weights/dinov3_base/model.safetensors \  
  --gpus 3,4,5,6,7 --study-name convnext_base_all \  
  --seed-run runs/cv/dino_base_first --n-trials 200
```

Trial в convnext_base_all	5-fold OOF mAP	Решение
0: исходный seed	0.705	Контрольная стартовая точка
23	0.759	Перенесенный рецепт для EVA02
74	0.760	Лучший ConvNeXt в study, но не выбран для переноса
Всего 82 испытания	76 complete; 4 pruned; 2 failed	Contest search space



История contest-space study: звездой отмечен trial 23, выбранный для переноса на EVA02. Цель - query-weighted full-gallery OOF mAP. Источник: [notebooks/eva02/readme_figs/optuna_history.png](#).

Trial 23 на EVA02 без внешнего MAD-Cars pretrain, после настройки K=4 и camera-diverse, дал 5-fold OOF mAP 0.862, mAP@10 0.851, Rank-1 0.848 при 35 эпохах. После MAD-Cars ep7 это выросло до 0.900 / 0.892 / 0.902. Важная оговорка: сравнение trial в одной 5-fold CV дает практический выбор рецепта, но тот же OOF уже не является независимым от HPO слепым тестом.

08. Итоговый конфиг и метрики

8.1. Точная конфигурация serving recipe

Основной файл: configs/experiment/current_best_tuned_madcars_full.yaml; backbone preset: configs/model/llm2clip.yaml; аугментации: configs/augmentation/reid_tilt.yaml; отказ: configs/refusal/eva02_ensemble.yaml. Числа ниже округлены для чтения, точные float-значения сохранены в YAML и checkpoint cfg.

Блок	Итоговые настройки
Backbone	LLM2CLIP EVA02-L-14-336, public snapshot → MAD-Cars full ep7; SDPA после RoPE, compile embedding wrapper.
Input	bbox + context 6.2017%, context jitter 8.5944%; stretch до 336×336; CLIP normalization.
Sampling	PK: 16 identity × 4 изображения, camera_diverse=true; per-epoch full dataset.
Features	Attention pooling (attention_hidden=128), BNNeck, 256-D retrieval feature neck, dropout 0.2222, local_parts=0.
Loss	ArcFace weight 0.3782, margin 0.47895 rad, scale 35.05; AdaSP weight 2.8263, temp 0.02607; оба на neck.
Optimizer	AdamW lr 6.9836e-4, weight decay 6.6246e-4, betas 0.94979/0.99832, eps 3.424e-8.
LR/schedule	Backbone LR multiplier 0.05018; layer decay 0.89347; linear scheduler, 2 warmup epochs, min LR ratio 0.10852.
Regularization	DropPath 0.08476; EMA decay 0.94061 (validate=true); gradient accumulation 4, clip 4.3734. R-Drop/AWP disabled.
CV/retrain	35-epoch CV budget, 5-fold GroupKFold; mean-stop full retrain 17 completed epochs; EMA export.
Inference	bf16 на профилях; top-10 cosine; TTA off; postproc off; fast_kernels=false; refusal AND: 0.5854/0.4034.

8.2. Реально включенные training-аугментации

Каждая операция в YAML имеет свой enabled, вероятность p и параметры. Ниже только операции с enabled=true; остальные доступные настройки остаются в конфиге, но на обучение не действуют. Для MAD-Cars tilt важны именно Affine vertical shear и дополнительная Perspective.


Группа	Включенные операции и p
Геометрия	HorizontalFlip 0.587; RandomResizedCrop 0.415; Affine 0.300 (vertical shear -12...4); Perspective 0.150.
Цвет/яркость	ColorJitter 0.019; RandomGamma 0.338; ToGray 0.151.
Качество	ImageCompression 0.00066; Downscale 0.139; GaussianBlur 0.156; MotionBlur 0.152.
Погода/закрытие	RandomFog 0.535; CoarseDropout 0.159; RandomErasing 0.216.

Возможность аугментации не равна ее применению в финале: например, RandomRain, RandomSnow, GridDropout, RandAugment и AugMix поддерживаются, но disabled в этом experiment. Усиленный пакет SOTA-аугментаций на labeled-only K=4+cam снизил mAP@10 с 0.851 до 0.850; для serving оставили выбранный рецепт.

8.3. Основные результаты

Протокол	mAP	mAP@10	Rank-1
EVA02 labeled-only K=4+cam, 35 ep, 5-fold OOF	0.862	0.851	0.848
MAD-Cars full ep7 → EVA02, 5-fold OOF	0.900	0.892	0.902

Разница финального рецепта и labeled-only при одинаковом 5-fold протоколе: +0.038 full mAP, +0.041 mAP@10, +0.054 Rank-1. Это не равномерный выигрыш по каждому query; подробный OOF-анализ дан далее. Nested open-set конкурсная величина для AND-ансамбля - 0.863. Все эти результаты локальные, а не официальный скрытый leaderboard.




Per-fold OOF метрики финального MAD-Cars fine-tune. Пять моделей оценивались только на своих held-out identity. Источник: [notebooks/eva02/readme_figs/current_best_folds.png](#).

09. OOF-анализ и сложные случаи

9.1. Что изменил MAD-Cars pretrain


Ноутбук `oof_compare.ipynb` сопоставляет на одинаковых запросах labeled-only K=4+cam и MAD-Cars fine-tune. Mean first-positive rank снизился 2.16 → 2.10. Rank-1 исправлен на 124 query, ухудшен на 41; 338 query выиграли AP, 186 проиграли, 1 017 не изменились. Изображение на Rank-1 совпадает между моделями лишь у 42% query; overlap top-5/top-10 равен 0.69/0.59. Это иной embedding space, а не простое монотонное увеличение всех cosine.

Raw cosine одного и того же изображения между двумя моделями около 0.26; после ортогонального Procrustes выравнивания 0.62. Linear CKA 0.48. На fold 0 внутриклассовый cosine 0.81 у labeled-only против 0.77 у MAD-Cars, cross-camera positive 0.75 против 0.69; negatives остаются около нуля. Более высокая mAP не требует роста каждого внутриклассового cosine: важен порядок конкретных positive и impostor.




Per-query AP: labeled-only K=4 против MAD-Cars fine-tune при одинаковых fold query и gallery. Часть запросов выигрывает, часть проигрывает. Источник: `notebooks/eva02/readme_figs/compare_ap.jpg`.

Fold-0 OOF: labeled-only vs madcars neighbors



Примеры спасенных и ухудшенных Rank-1 совпадений; зеленый означает верную identity, красный - ошибочную. Источник: notebooks/eva02/readme_figs/compare_neighbors.jpg.




Текущий labeled-only K=4 против MAD-Cars: одинаковые изображения сближаются после ортогонального выравнивания embedding spaces, а распределения positive и negative показаны отдельно. Источник: notebooks/eva02/readme_figs/compare_embed.jpg.

9.2. Срезы сложности

Срез на финальном OOF	mAP	Rank-1	Интерпретация
Все допустимые query	0.900	0.902	Опорный результат
Lookalikes	0.768	0.748	Похожие кузов и цвет у разных identity
Смена aspect/ракурса	0.872	0.858	Сильное изменение вида объекта
Blur	0.884	0.886	Размытие и низкая резкость


Срез на финальном OOF	mAP	Rank-1	Интерпретация
Night	0.887	0.904	Ночные условия
Малый bbox	0.892	0.889	Низкая детализация

Медиана числа истинных gallery совпадений - около трех на query. При искусственном ограничении каждой validation gallery до 750 изображений mAP 0.900 → 0.902, но Rank-1 0.902 → 0.888: изменение размера галереи может сдвигать выводы в разных направлениях. Сложнейшие ошибки связаны с near-miss lookalikes, а не случайными distractor.



Срезы сложности в финальном identity-disjoint OOF. Прямое сравнение с общим качеством корректно внутри того же протокола. Источник: notebooks/eva02/readme_figs/oof_difficulty_slices.jpg.

Fold OOF pairs: easy hits, lookalikes, and Rank-1 misses



Query и Rank-1 gallery кропы финального fold-0 OOF: наглядные удачи и ошибки сопоставления. Источник: notebooks/eva02/readme_figs/current_best_pairs.jpg.

10. Full retrain, экспорт и воспроизводимость

10.1. Выбор числа эпох

После CV финальная модель обучается на **всех** размеченных identity с `data.full_retrain=true`. Held-out validation больше нет; val/mAP checkpoint monitor не применим, сохраняется `last.ckpt` после фиксированного числа эпох. Число эпох берется как округленное среднее числа **завершенных** эпох лучших fold-checkpoints: $(20+26+10+12+19)/5=17.4$, значит 17 эпох (индексы 0-16). Имя `Lightning epoch025.ckpt` соответствует 26 завершенным эпохам, а не 25.

```
.venv/bin/python train.py \
  experiment=current_best_tuned_madcars_full \
  data.full_retrain=true data.cv_dir=runs/cv/madcars_full_ft_ep35 \
  init_checkpoint=runs/pretrain/madcars_full_pretrain_ep7/checkpoints/madcars_full_pretrain_ep7.pt \
  model.local_files_only=true \
  output_dir=runs/full/madcars_full_ft_ep35
```

Инициализация снова идет из MAD-Cars ep7, а не из предыдущего full-retrain .pt и не только из Hub snapshot. `data.cv_dir` может вычислить mean-stop автоматически. При обучении на всех train ID оценка через `eval.split=val` запрещена, поскольку identity fold оказались бы внутри train. Это ожидаемая защита от некорректной валидации.

10.2. Экспорт embedding модели и refusal head

```
.venv/bin/python scripts/export_serving.py \
  --checkpoint runs/full/madcars_full_ft_ep35/checkpoints/last.ckpt \
  --output weights/finetuned/eva02.pt --weights ema --sha256
.venv/bin/python scripts/export_refusal.py \
  --nested --cv runs/cv/madcars_full_ft_ep35 --update-config
.venv/bin/python scripts/export_refusal.py \
  --full-retrain --cv runs/cv/madcars_full_ft_ep35 \
  --checkpoint runs/full/madcars_full_ft_ep35/checkpoints/last.ckpt \
  --output weights/finetuned/eva02_catboost.cbm --sha256
```

Компактный .pt содержит `format=reid-serving`, resolved Hydra cfg, EMA `state_dict` и указание вида весов; `optimizer`, `Lightning loop` и лишняя raw копия исключены для лимита 2 GiB. CatBoost refit выполняется в embedding space финального .pt на 50/50 full-vs-stripped парах. **Пороги при этом не переобучаются** на in-sample full-retrain packs: `--nested` замораживает их по identity-disjoint OOF. Флаги `--full-retrain` `--update-config` намеренно несовместимы.

В `weights/finetuned/` находятся `eva02.pt`, `eva02_catboost.cbm`, `SHA256SUMS`. Эти веса - Git LFS объекты; Docker build проверяет checksum. CatBoost .cbm не входит в официальный 2 GiB glob weight-файлов, а .pt около 1.14 GiB. Resume Lightning checkpoint и transfer init checkpoint - разные операции: resume сохраняет `optimizer/epoch` и допускается только при совпадающ `data fingerprint/label map`.

11. Профилирование: H200, A5000, RTX 3090 и TensorRT

11.1. Что именно измеряется

Конкурсный latency относится к полному `extract()` одного изображения: чтение файла, `decode`, `bbox crop`, `preprocessing`, `forward`, `postprocessing` и L2-нормализация. `Gallery search` исключен. Профили `profiling/` используют тот же `decode/crop/DataLoader` путь, что `Docker` и `eval.py`, а не отдельный синтетический `forward`. Для `batch-1` фиксируются 50 прогревов и 300 последовательных измерений с `CUDA synchronize`; `throughput` измеряется не менее 10 секунд на `batch 1/8/16/32`. `Startup workers` и первая компиляция учитываются отдельно. Диагностические времена стадий нельзя суммировать: на каждой стадии есть дополнительная синхронизация.


Условие опубликованного performance score	Полный балл	Линейная область	Ноль
Latency, batch 1	≤40 мс	40-80 мс	>80 мс
Throughput, лучший batch	≥100 FPS	50-100 FPS	<50 FPS

Performance составляет 20% конкурсной оценки: 10% за `latency` и 10% за `throughput`. Весовой набор `inference`-файлов с разрешенными `suffix` должен быть ≤2 GiB; при превышении он не допускается к этой части оценки. Числа ниже - локальные измерения, не официальный балл организаторов.


11.2. PyTorch профили на трех GPU

GPU / режим	p50 batch-1	Лучший FPS	VRAM b32	Примечание
H200, compile	16.6 мс	532	1.18 GiB	Изолированный H200; TTA off, bf16; прежний экспорт той же архитектуры.
A5000, compile	26.5 мс	133.6	1.18 GiB	Vast.ai, driver 580.178.04; <code>fast_kernels=false</code> .
RTX 3090, compile	23.7 мс	119.9	1.18 GiB	Vast.ai, driver 535.113.01; рекламируемая CUDA 12.2.
RTX 3090, eager	40.5 мс	73.3	2.64 GiB	То же железо без <code>torch.compile</code> .

На 3090 `compile` улучшил теплую `batch-1 latency` 40.5 → 23.7 мс и `batch-32 throughput` 73.3 → 119.9 FPS, но первая компилируемая `extract()` заняла 31.59 с вместо 0.30 с `eager`. На H200 `wrapper load` 4.6 с, на A5000 6.3 с; тяжелая `compilation` оплачивается первым `forward`. Нельзя переносить H200 FPS на A5000 как обещание: отличаются GPU, CPU quota, драйвер, образ и параметры `kernels`.



Стадии полного batch-1 extract() на H200 после прогрева. Decode и forward измерены с отдельными CUDA synchronize. Источник: notebooks/eva02/readme_figs/inference_stages.png.




Sustained throughput H200 по batch size на том же DataLoader пути, что serving. Пик 532 FPS на batch 32. Источник: notebooks/eva02/readme_figs/inference_throughput.png.

11.3. Полный replay и совместимость CUDA

На A5000 полный offline serving replay обработал 1 110 test query и 750 gallery. С fast_kernels=false пустой compile cache дал 142.7 с; повторный прогон 67.3 с. Два запуска с false дали byte-identical embeddings, submission и candidates. Старое значение true давало 159.5 с на пустом кеше и один из запусков менял lower top-10 ranks, хотя top-1 оставался тем же; теперь default - false. В свежем контейнере холодный старт и компиляция входят в общий бюджет, даже если не входят в теплую latency_b1.

Чистый Dockerfile-equivalent replay на RTX 3090 с драйвером 535.113.01 (Vast показывал CUDA 12.2) поставил gcc в userspace CUDA 12.8, затем runtime requirements и запустил entrypoint. Он завершился за 129.2 с, записал все три файла и показал, что конкретная связка драйвер/образ/compile работала. Это не был docker build + docker run собранного submission image: Vast не разрешал Docker-in-Docker. Точная машина и версия драйвера организаторов не воспроизведены.



A5000 DataLoader throughput по batch size при fast_kernels=false; это отдельный хост и прежний экспорт той же архитектуры. Источник: notebooks/eva02/inference_profile_a5000_figs/throughput.png.

11.4. ONNX → TensorRT как опция

Экспортер создает fixed 336×336 ONNX с динамическим batch и FP16 TensorRT engine для конкретной GPU. Manifest проверяет hash checkpoint, EMA/raw, размер изображения, TensorRT version, модель GPU и compute capability. Engine надо строить заново под целевой runtime. Default Docker остается PyTorch; совместимость engine A5000 с иной машиной не предполагается.

A5000, одинаковые 32 crop	PyTorch bf16	TensorRT FP16
Median batch-1	26.0 мс	24.6 мс
p90 batch-1	37.8 мс	31.2 мс
Лучший throughput	133.0 FPS (b32)	128.5 FPS (b16)
Batch-32 throughput	133.0 FPS	115.0 FPS
Файлы checkpoint + engine	1 228 959 035 В	1 840 850 695 В
Расчетный performance	0.20 / 0.20	0.20 / 0.20

ONNX export занял 17.5 с, сборка engine 72.0 с; промежуточный ONNX около 1.22 GiB не должен лежать вместе с checkpoint+engine под лимитом 2 GiB. Полный test endpoint отдельным запуском прошел за 35.3 с с TensorRT против 67.3 с теплого PyTorch cache и 142.7 с холодного. Однако TensorRT изменил top-1 у 2/1 110 query и решение accept/refuse у двух query. Для принятия в serving нужен честный fold-checkpoint и оценка mAP@10/refusal на identity-disjoint OOF; финальный all-data .pt для такой проверки не подходит. TensorRT поэтому остался опцией.

```
python -m pip install -r requirements/tensorrt.txt
python -m scripts.export_tensorrt \
    checkpoint=weights/finetuned/eva02.pt \
    eval.tensorrt.onnx_path=/tmp/eva02.onnx \
    eval.tensorrt.engine_path=weights/finetuned/eva02_fp16.engine
python eval.py checkpoint=weights/finetuned/eva02.pt \
    eval.inference_backend=tensorrt \
    eval.tensorrt.engine_path=weights/finetuned/eva02_fp16.engine
```

12. Open-set refusal: протокол, модели и результат

12.1. Что должен решить отказ

В закрытом тесте около 20% query не имеют совпадения в gallery. Значение отказа - отсутствие строк для этого query_id в candidates.csv. submission.csv при этом все равно содержит десять кандидатов для **каждого** query. Правильный top-1 на closed query считается TP; неверный top-1 на closed query - FP. TNR относится только к open query. Организатор считает $0.7 \times F1 + 0.3 \times TNR$ по micro confusion matrix. Порог не вычисляется повторно на стороне scorer.

12.2. Данные обучения и признаки CatBoost

Для обучения бинарного head строятся сбалансированные 50/50 примеры: один и тот же query ищет в полной gallery ($y=1$) и в gallery с удаленной его identity ($y=0$). Но threshold оптимизируется и проверяется на более реалистичных 20% identity-hold-out packs. Feature extractor не получает vehicle_id или camera_id; они нужны только для конструирования меток. CatBoost использует 23 скалярных статистики top-10 соседей плюс нормализованные 256-D query и 256-D top-1 gallery embeddings, всего 535 числовых признаков.

Группа признаков	Что измеряет
Cosine top-10	top1/top2/top3, gap12/gap13, среднее/стандартное отклонение/медиана/минимум, mean top3/top5, entropy, margin к остальным.
Локальная геометрия	Средний и разброс pairwise cosine соседей; query к среднему соседу; числа cosine $\geq 0.5/0.7/0.9$.
Граф топ-10	Reciprocal nearest relation, число ребер, число компонент, clustering coefficient при cosine edge threshold 0.5.
Сырые координаты	Конкатенация L2-нормализованных 256-D query и top-1 gallery vectors.


Serving CatBoostClassifier refit на full-retrain embeddings использует 200 итераций, depth=4 и learning rate=0.08. В качестве альтернативы исследован TabM: parameter-efficient ensemble MLP с общими линейными весами и BatchEnsemble rank-1 масштабами; итоговый Docker head - CatBoost, не TabM.

12.3. Nested calibration и выбор ensemble


Пять внешних folds дают OOF оценку. Для каждого outer fold CatBoost/TabM обучается на четырех folds 50/50 пар; пороги cosine и модели выбираются на inner eval packs с 20% open-set; outer pack оценивается без переоптимизации. Средние nested operating points записаны в configs/refusal/. PR-AUC на непрерывном score является только диагностикой, не конкурсным баллом.

Head	Nested contest score	Serving cut
Только max cosine	0.857	cosine ≥ 0.5854
CatBoost	0.862	P(match exists) ≥ 0.4034
AND ensemble	0.863	Оба условия одновременно; default Docker


ArcFace margin 0.479 rad и AdaSP temperature 0.026 не являются готовыми порогами cosine. Они задают относительную геометрию обучения внутри PK batch; max impostor в gallery из сотен crop - другая величина. Порог 0.5854 подбирается эмпирически на nested open-set packs. При переносе этих порогов с fold extractors на full-retrain модель не возникает новой held-out оценки final checkpoint.



Распределение max query-gallery cosine для closed/open query на 20% identity-hold-out финального MAD-Cars OOF. Источник: [notebooks/eva02/readme_figs/refusal_cosine_geometry.jpg](#).



Стабильность cosine threshold и качества при восьми фиксированных hold-out seed; cut 0.5854. Источник: [notebooks/eva02/readme_figs/refusal_holdout_seeds.jpg](#).



Срезы refusal: lookalikes с высоким impostor cosine особенно ухудшают TNR. Источник: notebooks/eva02/readme_figs/refusal_slices.jpg.

Графики `refusal_contest_ci.jpg`, `refusal_bars.jpg` и `refusal_pr.jpg` в репозитории относятся к более раннему labeled-only nested OOF. Их нельзя подписывать как оценку финального MAD-Cars serving head; финальные headline-цифры - 0.857/0.862/0.863 из текущего README.

13. TTA, postprocessing и псевдоразметка

13.1. Какие операции совместимы с потоковым тестом

Организатор рассматривает query как независимый поток; gallery статична и может индексироваться заранее. Поэтому разрешены per-image flip/rotation/context TTA, gallery-only агрегация соседей и per-query GNN/k-reciprocal rerank без query-query графа. Query expansion, включая AQE gallery_only, а также методы, использующие другие test query или их результаты, запрещены. В конфиге postproc.streaming=true и eval.py отклоняет AQE в этом режиме.

TTA усредняет embedding только текущего crop: горизонтальный flip, небольшие rotation и дополнительный bbox context. LLM2CLIP/EVA02 зафиксирован на 336x336 и допускает только scales=[1.0]; другие backbone могут применять scale-TTA. Финальный рецепт оставляет TTA выключенным, так как каждый дополнительный view требует forward и sweep не был повторен на финальном MAD-Cars K=4 OOF.

K=2 ранний 5-fold OOF	mAP@10	Δ к base	Статус
Без TTA/postproc	0.834	-	База
hflip	0.847	+0.013	Разрешено, не в serving
hflip + rotation ±4°	0.848	+0.014	Разрешено, не в serving
Gallery aggregation	0.836	+0.002	Разрешено, не в serving
GNN rerank	0.842	+0.008	Разрешено per query, не в serving
k-reciprocal rerank	0.824	-0.010	Ухудшение
AQE query + gallery	0.849	+0.015	Запрещено

DBA k=5 sim³ показала full mAP 0.860 (mAP@10 не сохранен); комбинация TTA+AQE дала округленный full mAP 0.862, но не допускается правилами. Эти числа принадлежат **раннему K=2**, а не финальному MAD-Cars K=4; нельзя переносить прирост без отдельного CV. Dense rerank оценивает память заранее и останавливается при превышении postproc.max_dense_gb.

13.2. HDBSCAN test pseudo-labels: что делали и почему не взяли

Итерация извлекает embeddings всех уникальных test query и gallery, кластеризует L2-векторы HDBSCAN, удаляет noise -1, присваивает кластерам новые vehicle_id и добавляет их к исходному labeled train. Следующая итерация повторяет кластеризацию заново, всегда объединяя с **исходным data/train.csv**. Валидируемые исходные identity остаются отдельными по fold; pseudo-ID получают fold=-1 и всегда находятся в train. Инициализация fold не может идти из all-data serving checkpoint, уже видевшего будущие held-out ID.

K=2 trial23 recipe	Кластеры	Test labeled	Noise	OOF mAP/mAP@10/R1
Labeled-only	-	-	-	0.847 / 0.834 / 0.842
HDBSCAN mcs4 iter1	234	1 626	13%	0.857 / 0.846 / 0.853
HDBSCAN mcs4 iter2	239	1 738	6.6%	0.856 / 0.845 / 0.850

Iter1 дал +0.012 mAP@10 на старом K=2 протоколе. Iter2 уменьшил noise, но не превысил качество iter1. Сравнение моделей показало 83 спасенных и 66 сломанных Rank-1; у 54% query сохранилось то же Rank-1 изображение, top-5/top-10 overlap 0.74/0.67. Это исследовательский результат, **не** состав финального eva02.pt: организаторы запретили test pseudo-labels.

Файлы readme_figs/compare_ap.jpg и compare_embed.jpg были регенерированы ноутбуком oof_compare.ipynb для текущего сравнения labeled-only K=4 против MAD-Cars. Поэтому графики из них приведены в главе 9, а не как иллюстрация исторического pseudo-label эксперимента.


Схема одной итерации и контроль leakage

Шаг	Действие	Проверка
1. Признаки	Fold-модель кодирует уникальные test query и gallery.	Не использовать all-data serving checkpoint для оценки held-out fold.
2. Кластеры	HDBSCAN по L2 embeddings; noise с label -1 исключается.	ID кластеров не приравниваются к исходным vehicle_id.
3. Тренировка	Новые pseudo-ID с fold=-1 объединяются с исходным labeled train.	На следующей итерации снова начинать с исходного train, а не копить прежние псевдометки.
4. Оценка	Исходные held-out query оцениваются на своем fold.	Исторический K=2 результат остается исследовательским.


14. Интерпретация embedding и cosine пары

Интерпретация interp/ объясняет не logit класса, а retrieval embedding. Без gallery reference target - энергия embedding до нормализации; при заданном gallery vector target - cosine(query, gallery). interpret_pair пропускает оба кропа через модель и атрибутирует обе стороны общего cosine. Это исследовательские heatmaps, в ranking они не входят.

Метод	Что показывает
Attention pooling	Пространственные веса реально обученного pooler, агрегирующего patch features.
Last attention / rollout	CLS-to-patch и свертка attention с residual; сама модель не извлекает retrieval по CLS.
Gradient rollout / Chefer	Attention, взвешенное gradient cosine; transformer attribution.
GradSim	gradient × activation на последних patch tokens относительно cosine пары.
Grad-CAM, HiResCAM, LayerCAM, EigenCAM	Варианты activation/gradient карт; EigenCAM без меток и gradient.
Occlusion	Падение cosine при закрытии блока patches; честный, но дорогой по числу forward метод.



Набор attribution методов на одних fold-0 OOF query. Energy maps и pairwise карты имеют разные target. Источник: notebooks/eva02/readme_figs/interp_methods.jpg.



Для query и gallery одновременно объясняется $\cos(z_q, z_g)$ методами GradSim, gradient rollout, occlusion и Chefer. Источник: notebooks/eva02/readme_figs/interp_pairs.jpg.


Теплые зоны означают положительный вклад в текущий cosine. Они не доказывают, что модель «смотрит только на нужную деталь», и не являются independent validation или механизмом исправления prediction.

15. Пост-хок устойчивость к искажениям


posthoc/ оставляет gallery чистой и меняет только один query crop, создавая k копий с severity 1-5. Сравниваются embedding cosine с clean query, угол, agreement копий, overlap/Jaccard/Kendall top-k, сохранение Rank-1 изображения/identity и изменение AP. Это анализ уже обученной модели, не дополнительное обучение и не TTA serving.

Группа corruptions	Примеры
Шум/сжатие	Gaussian noise, impulse noise, JPEG, downsample.
Размытие	Gaussian blur, motion blur.
Свет/цвет	Brightness, contrast, saturation, fog.
Геометрия/окклюзия	Rotate, crop, occlude.

Небольшие JPEG/blur/color сдвиги почти не меняют embedding. Самый чувствительный сценарий - сильный повторный crop: средний cosine clean-vs-corrupted около 0.59 при severity 5. Сильная окклюзия и downsample также снижают стабильность. Сравнение с пиксельным L1 показывает, что геометрический re-crop может менять признак сильнее, чем шум с аналогичной среднепиксельной величиной.



Средний cosine clean и corrupted query embedding; чистая gallery фиксирована. Источник: [notebooks/eva02/readme_figs/posthoc_cosine.jpg](#).




Пиксельный L1 против cosine embedding: сильный crop оказывается особо разрушительным. Источник: [notebooks/eva02/readme_figs/posthoc_sensitivity.jpg](https://notebooks.eva02.readme_figs/posthoc_sensitivity.jpg).

16. Локальный image matching: EfficientLoFTR


matching/ применяет detector-free semi-dense EfficientLoFTR только к shortlist cosine top-10, а не к полной gallery. Он выдает число correspondences выше threshold 0.2, сумму/среднюю confidence, число RANSAC homography inliers и inlier ratio. Цель эксперимента - проверить, можно ли геометрией улучшить ranking или объяснить ошибки. Веса загружаются отдельно в weights/efficientloftr, offline local_files_only=true.

Fold-0 K=4+cam 35 ep	Результат
Среднее число inliers: same ID / impostor	52 / 35; распределения сильно пересекаются.
Cosine Rank-1 → inlier-count rerank Rank-1	0.851 → 0.401.
Исправлено / сломано	Спасены 5 из 46 ошибок, сломаны 144 из 263 правильных top-1.

Похожие цвет и текстура дают много correspondence даже между разными машинами; hard inlier-count rerank разрушает сильный глобальный retrieval signal. EfficientLoFTR оставлен как визуальный second opinion для разбора пары, но не входит в submission. Код поддерживает reorder_head и hybrid_head внутри top-k, однако показанный простой геометрический verifier ухудшил метрику.



Примеры истинной и ложной пары с semi-dense correspondences и RANSAC проверкой. Источник: notebooks/eva02/readme_figs/matching_pairs.jpg.



Облака same-ID и impostor inliers перекрываются; одной геометрической статистики недостаточно для gerank. Источник: notebooks/eva02/readme_figs/matching_verifier.jpg.

17. Неудавшиеся и невыбранные эксперименты

Следующая таблица группирует эксперименты только внутри совместимого протокола. «Не вошло» не всегда означает бесполезно: часть методов запрещена правилами, часть дает локальный прирост, но увеличивает latency или не проверена на финальной модели, а часть действительно ухудшает метрику.

Эксперимент	Протокол	Результат	Почему не serving
SOTA аугментации	Labeled-only K=4+cam, 5-fold	mAP@10 0.851 → 0.850	Не дали прироста.
SphereFace2 + AdaSP	Тот же K=4+cam, 5-fold	0.851 → 0.845	Ниже ArcFace + AdaSP.
InfoNCE / NT-Xent	Тот же K=4+cam, 5-fold	0.851 → 0.843	Ниже базового loss.
Triplet semihard	Тот же K=4+cam, 5-fold	0.851 → 0.834	Ниже базового loss.
PK K=6 + cam	EVA02 trial23, 5-fold	mAP@10 0.844	Не лучше K=4 на том же trial23.
Multilevel blocks 12/18/24	K=2, 5-fold	mAP@10 0.826	Ниже K=2 base 0.834.
Multilevel late	K=2, 5-fold	mAP@10 0.833	Почти baseline, без выигрыша.
k-reciprocal	K=2, 5-fold	0.834 → 0.824	Ухудшил ranking.
EfficientLoFTR inlier rerank	K=4+cam, fold 0	Rank-1 0.851 → 0.401	Непригоден как простой ranker.
VRIC pretrain	3-fold pretrain sweep	mAP@10 0.806	MAD-Cars tilt дал 0.868 на 3-fold.
MAD-Cars + VRIC mix	3-fold pretrain sweep	mAP@10 0.849	Ниже MAD-Cars tilt 0.868.

TTA hflip/rotation и GNN rerank улучшали ранний K=2 OOF, поэтому называть их провалом неверно; они не перенесены в финал из-за дополнительных forward/compute и отсутствия отдельного финального MAD-Cars OOF sweep. TensorRT дал локальный latency выигрыш и более быстрый отдельный full replay, но batch-32 throughput ниже и 2/1 110 top-1 изменились; без честной fold-валидации он остался optional. Псевдоразметка test и AQE не включены по правилам, несмотря на улучшения в исследовательском K=2 OOF.

Итоговые границы утверждений

- 0.892 mAP@10 - локальный identity-disjoint retrieval OOF fold-моделей, не оценка full-retrain .pt на скрытом тесте.
- 0.863 отказа - nested 20% open-set оценка при 5-fold calibration, не официальный contest result.
- H200/A5000/3090 профили - измерения прежних экспортов той же архитектуры, со своими CPU и драйверами.
- RTX 3090 с драйвером, рекламирующим CUDA 12.2, прошел чистый Dockerfile-equivalent replay, но фактический built-image запуск на машине организаторов остается отдельной проверкой.
- Исторические notebook-графики labeled-only не подменяют финальные MAD-Cars OOF результаты.

18. Проверки, артефакты и карта источников

18.1. Контроль после воспроизведения

- Проверить доступность настоящих LFS весов и SHA256SUMS, после чего выполнить `scripts/verify_weights.py`.
- Запустить `make audit` и `make folds`; проверить `fingerprint`, `seed`, число `folds` и отсутствие пересечения `train/val identity`.
- Запустить `make smoke`, `make lint`, `make test`; README заявляет строгие Ruff/ty и 100% line coverage первого Python-кода.
- Для `fold validation` брать `checkpoint` из соответствующего `run_summary.json`, не финальный `.pt`.
- Для конкурса выполнить `offline Docker command` и проверить `headerless submission.csv` (по 10 IDs на `query`), форму `embeddings.npy` и отсутствие `refused query` в `candidates.csv`.
- Отдельно измерить `cold start`, полный `extract()`, `throughput` и пик `VRAM` на целевом GPU; не приравнивать измерения другого хоста к официальным.

18.2. Где искать первоисточник каждого числа

Тема	Файлы репозитория
Итоговая модель/метрики	README.md, configs/experiment/current_best_tuned_madcars_full.yaml, notebooks/eva02/oof_analysis.ipynb, runs/cv/madcars_full_ft_ep35/cv_metrics.json.
Pretrain/tilt	README.md раздел Pretraining, configs/augmentation/reid_tilt.yaml, scripts/run_madcars_full_pretrain.sh.
Optuna	README.md раздел Hyperparameter optimization, hpo/optuna_search_space.py, notebooks/eva02/readme_figs/optuna_history.png.
Отказ	refusal/features.py, refusal/protocol.py, configs/refusal/eva02_ensemble.yaml, notebooks/eva02/refusal_analysis.ipynb.
Профили	notebooks/eva02/inference_profile*.ipynb, notebooks/eva02/*profile*_figs/report*.json, profiling/.
TTA/postproc/pseudo	README.md Research and optional methods, postproc/, scripts/pseudo_label.py, notebooks/eva02/oof_compare.ipynb.
Интерпретация/post-hoc/matching	interp/, posthoc/, matching/ и соответствующие notebooks/eva02/*.ipynb.

Источники внешних данных и библиотек: <https://huggingface.co/datasets/yandex/mad-cars> (MAD-Cars, CC BY-NC-SA 4.0), <https://qmul-vric.github.io/> (VRIC), VeRi-776 на Kaggle (CC BY-NC 4.0), Microsoft LLM2CLIP Hub checkpoint. Перед повторным распространением исходных датасетов следует проверить лицензии. Финальный Docker runtime использует `offline weights` и не скачивает исходные наборы.